

NYC Taxi — Data Engineering

Pipeline analytique 2022–2024 avec Python, Snowflake et dbt

100,3 M lignes RAW

97,64 M lignes propres


22/22 tests dbt

1. Contexte et objectif

- Exploiter les données Yellow Taxi sur trois années : 2022, 2023 et 2024.
- Construire une chaîne reproductible d'ingestion, de nettoyage, de transformation et de contrôle qualité.
- Séparer les responsabilités : Python pour l'ingestion, Snowflake pour le stockage, dbt pour les transformations et les tests.
- Produire des tables finales directement exploitables pour l'analyse quotidienne, horaire et géographique.

2. Architecture technique

Une architecture en couches claire et reproductible.



- Snowflake Internal Stage utilisé avant COPY INTO.
- RAW conserve les données chargées avant les transformations dbt.

3. Données et ingestion

36 fichiers Parquet — 12 par année.

Période

2022–2024

36 fichiers

RAW Snowflake

100,319,438

lignes chargées

Période cible

100,318,800

lignes 2022–2024

- Chargement fichier par fichier avec PUT puis COPY INTO.
- 0 erreur de chargement sur les fichiers traités.
- 638 lignes présentent une date de prise en charge hors période cible et sont éliminées au nettoyage.
- Le volume local DuckDB et le volume RAW Snowflake diffèrent ; ce point reste documenté comme contrôle complémentaire.

4. Qualité des données

Des règles explicites, mesurées et testables.

Initial

100,319,438

Conservées

97,643,478

Rejetées

2,675,960

2,67 %

- Dates limitées à 2022–2024 et cohérence dropoff $\geq$ pickup.
- Montants négatifs exclus pour total, fare, tip et tolls.
- Distances > 200 km exclues.
- Durées négatives ou supérieures à 24 h exclues.
- Passenger_count NULL conservé et documenté plutôt qu'imputé arbitrairement.

5. Enrichissement métier

Durée

minutes

Vitesse

km/h

Tip rate

%

Distance

4 catégories

Période

4 créneaux

Jour

Weekday / Weekend

- Seuils analytiques : vitesse ≤ 120 km/h et tip rate ≤ 100 %.
- Les valeurs hors seuil sont conservées sous forme de NULL afin de ne pas déformer les agrégats.

6. Les 3 modèles analytiques FINAL

daily_trips

920 lignes

grain : date

hourly_patterns

48 lignes

heure × type de jour

zone_analysis


1 048 lignes

zone × distance

- daily_trips : évolution des courses, chiffre d'affaires, distance, durée, vitesse et pourboire.
- hourly_patterns : analyse par heure, période de la journée et type de jour.
- zone_analysis : analyse des zones de départ et catégories de distance.


7. Tests et qualité logicielle

La qualité est intégrée au pipeline dbt.



- Tests not_null sur les dimensions et mesures critiques.
- Tests d'unicité adaptés au grain des modèles.
- Tests de combinaison unique pour hourly_patterns et zone_analysis.
- Tests métier sur les mesures non négatives et cohérentes.
- Macros dbt personnalisées : non_negative et unique_combination.

8. Compétences mobilisées



- Le projet met en pratique une chaîne Data Engineering complète de bout en bout.
- Prochaines pistes : orchestration, CI/CD dbt, observabilité et Infrastructure as Code.

Conclusion

- Chaîne Data Engineering complète et reproductible.
- Règles de qualité explicites et mesurées.
- Trois modèles analytiques adaptés à des grains différents.
- 22 tests dbt réussis sur la dernière exécution.
- Projet versionné et documenté sur GitHub.

Merci — Questions / échanges